

INSEA
Institut National de Statistique
et d'Économie Appliquée



Haut-Commissariat au Plan

Grand Projet Encadré — Data Science

Détection Cost-Sensitive de Manipulation de Marché

*Threshold Moving — Calibration Probabiliste — SMOTE
Data Drift Monitoring — Dashboard Décisionnel*

Réalisé par : Aboussad Taoufiq ET Oukessou Soufiane

Filière : Data Science

Encadre par : Mr Benyaacoub Badreddine

Domaine : Finance de marché, conformité et surveillance

Méthodes : ML, Cost-Sensitive, Calibration,
Threshold Moving, SMOTE, Drift, Dashboard

Table des matières

Introduction	2
1 Contexte métier et problématique	2
2 Fondements théoriques	3
2.1 Pourquoi l'accuracy ne suffit pas	3
2.2 Fonction de coût et matrice de coûts	3
2.3 Théorie de décision de Bayes et seuil optimal	3
2.4 Threshold Moving	4
2.5 Calibration probabiliste	4
2.6 SMOTE	4
2.7 Data Drift	4
3 Construction du dataset	4
3.1 Collecte et variables brutes	4
3.2 Feature engineering	4
3.3 Génération des labels	5
3.4 Distribution des classes	5
4 Méthodologie expérimentale	8
4.1 Split temporel	8
4.2 Pipeline global	9
5 Modélisation et résultats baseline	9
5.1 Choix des modèles	9
5.2 Résultats avec seuil 0.5	9
6 Calibration probabiliste	11
7 Threshold Moving et analyse cost-sensitive	14
7.1 Optimisation du seuil	14
7.2 Résultats après Threshold Moving	15
8 Comparaison avec SMOTE	18
9 Monitoring du Data Drift	19
9.1 Feature drift	19
9.2 Label drift et dégradation du coût	19
9.3 Recalibration automatique	20
10 Dashboard interactif : Market Abuse Command Center	20
Conclusion	21

Introduction

Dans les marchés financiers modernes, chaque actif produit en continu un flux de données : prix, volumes, volatilité, rendements. Ces chiffres ne sont pas de simples indicateurs ; ils racontent le comportement du marché, ses phases calmes, ses tensions, ses épisodes spéculatifs. Parmi ces comportements, la manipulation de marché reste l'un des phénomènes les plus difficiles à détecter, non pas parce qu'il est invisible, mais parce qu'il est rare, subtil, et que ses manifestations se superposent à celles d'une volatilité normale.

Ce projet part d'un constat simple mais fondamental : un modèle classique de classification ne suffit pas pour répondre à ce type de problème. Entraîné sur des données fortement déséquilibrées, un tel modèle sera naturellement tenté de prédire presque toujours la classe majoritaire — le comportement normal — obtenant ainsi une accuracy trompeuse, mais ratant systématiquement les rares cas suspects. Or, dans un contexte de surveillance financière, rater une manipulation coûte infiniment plus cher que déclencher une fausse alerte. C'est cette asymétrie fondamentale qui motive l'ensemble de la démarche.

Objectif central

Construire un système de détection qui ne se contente pas d'optimiser des métriques statistiques, mais qui minimise le coût économique réel des erreurs de classification.

Le travail réalisé couvre la chaîne complète : collecte de données réelles de marché, construction de variables financières pertinentes, génération de labels de suspicion, entraînement et calibration de modèles, optimisation du seuil par *Threshold Moving*, comparaison avec SMOTE, surveillance du data drift, recalibration automatique et développement d'un dashboard interactif baptisé *Market Abuse Command Center*.

1 Contexte métier et problématique

La manipulation de marché désigne tout comportement visant à perturber artificiellement le fonctionnement d'un marché financier. Elle peut prendre des formes très variées : hausses artificielles de prix, volumes inhabituels, séquences d'ordres coordonnées, ou épisodes spéculatifs extrêmes. Pour une institution financière ou un régulateur, l'enjeu n'est pas uniquement de détecter ces anomalies, mais aussi de les prioriser. Les analystes de conformité ont un temps limité ; le système doit donc être conçu pour diriger leur attention vers les cas réellement critiques.

La question centrale du projet est la suivante : comment construire un modèle qui minimise le coût total des erreurs plutôt que de maximiser une précision statistique ? Cette question engage deux types d'erreurs dont les conséquences sont radicalement asymétriques.

Asymétrie des erreurs

Un **faux positif** (fausse alerte) représente le coût d'une enquête inutile — limité mais réel. Un **faux négatif** (manipulation non détectée) expose l'institution à des pertes financières massives, des sanctions réglementaires et un risque de réputation durable. C'est le faux négatif qui constitue l'erreur critique.

2 Fondements théoriques**2.1 Pourquoi l'accuracy ne suffit pas**

Dans un dataset fortement déséquilibré où la classe suspecte représente moins de 3% des observations, un modèle qui prédit systématiquement la classe normale obtient une accuracy supérieure à 97% sans jamais détecter la moindre manipulation. La formule $\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$ donne le même poids à un faux positif et à un faux négatif — hypothèse qui est précisément fautive dans ce contexte. Il faut donc des métriques qui distinguent la gravité des erreurs, et surtout une fonction de coût qui traduit cette gravité en euros.

2.2 Fonction de coût et matrice de coûts

La fonction de coût utilisée est :

$$\text{Cost} = c_{FN} \times FN + c_{FP} \times FP$$

Les valeurs retenues représentent un scénario de référence plausible pour une institution financière :

$$c_{FN} = 15\,000\,000 \text{ €} \quad c_{FP} = 7\,000 \text{ €}$$

L'écart de plus de deux mille entre ces deux coûts explique toute la logique du projet : il vaut mieux déclencher de nombreuses fausses alertes que de rater une seule manipulation réelle.

2.3 Théorie de décision de Bayes et seuil optimal

Pour chaque observation, un modèle probabiliste produit $\hat{p}(x) = P(Y = 1|x)$. La décision rationnelle consiste à comparer le risque de chaque action. Déclencher une alerte coûte $c_{FP}(1 - p)$, ne pas la déclencher coûte $c_{FN} \cdot p$. On déclenche donc une alerte quand $c_{FP}(1 - p) < c_{FN} \cdot p$, ce qui conduit au seuil optimal théorique :

$$t^* = \frac{c_{FP}}{c_{FN} + c_{FP}} = \frac{7\,000}{15\,007\,000} \approx 0.000467$$

Ce résultat est contre-intuitif mais cohérent : avec une telle asymétrie de coûts, il est rationnel de déclencher une alerte même lorsque la probabilité prédite est très faible.

2.4 Threshold Moving

Le *Threshold Moving* ne modifie pas le modèle — il modifie la règle de décision. Au lieu d'utiliser le seuil conventionnel de 0.5, on cherche sur un ensemble de validation le seuil t qui minimise $\text{Cost}(t) = c_{FN} \times FN(t) + c_{FP} \times FP(t)$. Cette approche transforme directement une probabilité en décision économique justifiée.

2.5 Calibration probabiliste

Le Threshold Moving repose sur les probabilités produites par le modèle. Si ces probabilités sont mal calibrées — c'est-à-dire si un score de 0.3 ne correspond pas réellement à une probabilité de 30% — le seuil choisi devient fragile. Deux méthodes de calibration sont utilisées : le *Platt Scaling* (transformation sigmoïde) et la régression isotonique (transformation monotone flexible). La calibration ne cherche pas à améliorer l'accuracy, mais à rendre les probabilités exploitables pour une décision cost-sensitive.

2.6 SMOTE

SMOTE (Synthetic Minority Over-sampling Technique) génère des exemples synthétiques de la classe minoritaire entre des observations proches dans l'espace des features. Il répond à la question : comment aider le modèle à mieux apprendre la classe rare lors de l'entraînement ? C'est une réponse statistique au déséquilibre, distincte du Threshold Moving qui est une réponse économique à la prise de décision.

2.7 Data Drift

En finance, les distributions changent. Un modèle entraîné sur 2019–2021 peut devenir moins fiable en 2023 si les niveaux de prix et de volume ont fortement évolué. Le data drift peut concerner les variables explicatives (*feature drift*), la fréquence de la classe positive (*label drift*) ou la performance économique du modèle (*cost degradation*). Deux mesures sont utilisées : le test de Kolmogorov-Smirnov et le *Population Stability Index* (PSI), avec les seuils classiques : $PSI < 0.1$ stable, $0.1 \leq PSI < 0.2$ drift modéré, $PSI \geq 0.2$ drift significatif.

3 Construction du dataset

3.1 Collecte et variables brutes

En l'absence de datasets publics labellisés sur la manipulation de marché, le projet s'appuie sur des données Yahoo Finance sur la période 2019–2023, couvrant cinq actifs : GME, AMC, AAPL, MSFT et le CAC 40 (FCHI). Les données brutes — Open, High, Low, Close, Volume — servent de base à une phase de feature engineering destinée à capturer les comportements anormaux.

3.2 Feature engineering

Les variables brutes seules ne suffisent pas à caractériser une manipulation potentielle, qui se manifeste généralement à travers des comportements relatifs plutôt qu'absolus. Plusieurs familles de variables sont donc construites.

Les **variables de prix** incluent le rendement simple et logarithmique, le rendement

anormal, la moyenne et l'écart-type mobiles du prix, le z-score du prix, le range journalier et le corps de la bougie. Les **variables de volatilité** couvrent la volatilité réalisée sur 5 et 20 jours, ainsi que leur ratio. Les **variables de volume** décrivent le volume moyen mobile, son écart-type, le volume anormal, son z-score et sa variation. Enfin, une **variable d'interaction** capture les cas où plusieurs anomalies coïncident :

$$\text{Interaction} = |\text{AbnormalReturn}| \times \text{AbnormalVolume}$$

Une hausse de prix seule ou un volume élevé seul ne sont pas nécessairement suspects. C'est leur combinaison qui devient informative.

3.3 Génération des labels

Les labels de suspicion sont construits par accumulation de signaux statistiques. Cinq indicateurs binaires sont activés lorsqu'une observation dépasse un seuil critique : rendement anormal élevé, volume anormal élevé, z-score de prix élevé, volatilité élevée, interaction prix-volume élevée. Le score de suspicion est leur somme, et une observation est labellisée suspecte si ce score atteint ou dépasse 3 :

$$\text{Label} = \begin{cases} 1 & \text{si SuspicionScore} \geq 3 \\ 0 & \text{sinon} \end{cases}$$

Note méthodologique

Ces labels sont des proxies académiques de suspicion, non des preuves juridiques. Ils servent à construire un cadre expérimental défendable pour tester les approches cost-sensitive.

3.4 Distribution des classes

Classe	Observations	Proportion
Normal	5 997	97.61%
Manipulation suspecte	147	2.39%

TABLE 1 – Distribution globale des labels




FIGURE 1 – Distribution globale des classes

Le déséquilibre est prononcé : la classe suspecte représente moins de 2.4% des observations. Ce ratio justifie pleinement le recours à des méthodes adaptées aux classes rares. On notera que les actifs GME et AMC concentrent davantage de signaux suspects — résultat cohérent avec leur historique de forte volatilité et d'épisodes spéculatifs bien documentés.




FIGURE 2 – Distribution des classes par actif

L'évolution temporelle des signaux suspects révèle un autre aspect important : les anoma-

lies apparaissent par épisodes concentrés dans le temps plutôt qu'uniformément réparties. Ce caractère épisodique est cohérent avec la réalité des manipulations de marché, qui surviennent souvent en séquences.




FIGURE 3 – Évolution temporelle des événements suspects




FIGURE 4 – Distribution du score de suspicion




FIGURE 5 – Matrice de corrélation des variables financières

La matrice de corrélation révèle que les variables de niveau (prix bruts, moyennes mobiles) sont fortement corrélées entre elles, tandis que les variables relatives (ratios, z-scores, interactions) apportent une information plus spécifique et complémentaire.

4 Méthodologie expérimentale

4.1 Split temporel

Pour imiter les conditions réelles de surveillance — on s'entraîne sur le passé et on prédit le futur — le dataset est divisé chronologiquement en quatre ensembles :

Ensemble	Observations	Classe 0	Classe 1	Taux positif
Train	3 686	3 585	101	2.74%
Validation calibration	614	601	13	2.12%
Validation seuil	615	607	8	1.30%
Test	1 229	1 204	25	2.03%

TABLE 2 – Split temporel du dataset

Cette structuration évite toute fuite temporelle et permet de calibrer et tester les modèles sur des données jamais vues durant l’entraînement.

4.2 Pipeline global

Le pipeline suit une logique séquentielle : téléchargement des données, feature engineering, génération des labels, split temporel, entraînement des modèles, calibration probabiliste, optimisation du seuil, comparaison avec SMOTE, drift monitoring, recalibration automatique et construction du dashboard interactif.

5 Modélisation et résultats baseline

5.1 Choix des modèles

Trois modèles constituent le socle de l’analyse. Le **Régression Logistique** joue le rôle de modèle de référence : simple, rapide, interprétable, elle fournit une base linéaire solide contre laquelle comparer les modèles plus complexes. Le **Random Forest** capture les relations non linéaires et les interactions entre variables, ce qui la rend particulièrement adaptée quand plusieurs signaux doivent être combinés pour détecter une anomalie. Enfin, **XGBoost** maximise la performance prédictive grâce à son mécanisme de boosting qui corrige progressivement ses erreurs — au prix d’une attention accrue portée à la calibration des probabilités.

5.2 Résultats avec seuil 0.5

Modèle	Accuracy	Precision	Recall	F1	AUC	FP	FN
Logistic Regression	0.9756	0.4545	1.0000	0.6250	0.9972	30	0
Random Forest	0.9911	0.7059	0.9600	0.8136	0.9979	10	1
XGBoost	0.9959	0.8333	1.0000	0.9091	0.9995	5	0

TABLE 3 – Résultats baseline avec seuil 0.5

Les trois modèles affichent d’excellentes performances statistiques avec un seuil standard de 0.5. XGBoost se distingue avec la meilleure combinaison précision-rappel et une AUC de 0.9995. Mais ces résultats, bien qu’encourageants, restent incomplets : ils ignorent entièrement le coût asymétrique des erreurs.




FIGURE 6 – Courbes ROC des modèles




FIGURE 7 – Courbes Precision-Recall

6 Calibration probabiliste

Avant d'appliquer le Threshold Moving, il est essentiel que les probabilités produites par les modèles soient fiables. Un modèle peut très bien classer les observations correctement — bonne AUC — tout en produisant des probabilités distordues. Dans ce cas, un score de 0.2 ne signifie pas forcément une probabilité réelle de 20%, et le seuil de décision devient fragile.

Modèle	Brier Score	AUC	Log Loss
Logistic Regression + Sigmoid	0.007151	0.9972	0.0247
Random Forest + Sigmoid	0.005828	0.9979	0.0200
XGBoost + Isotonic	0.003601	0.9790	0.0910

TABLE 4 – Résultats de calibration

La Random Forest calibrée présente le meilleur équilibre entre Brier Score et AUC. XGBoost obtient le meilleur Brier Score mais perd en capacité de séparation après calibration isotonique — compromis qu'il faudra garder en tête lors de l'interprétation des résultats cost-sensitive.




FIGURE 8 – Courbes de calibration — rapprochement vers la diagonale




FIGURE 9 – Importance des variables selon la Random Forest




FIGURE 10 – Importance des variables selon XGBoost

Les deux modèles accordent une importance significative aux variables de volume et aux interactions prix-volume, ce qui confirme que le feature engineering a bien capturé les signaux pertinents. La cohérence entre les deux familles de modèles renforce la robustesse de cette interprétation.




FIGURE 11 – Distribution des probabilités prédites — Random Forest calibrée




FIGURE 12 – Distribution des probabilités prédites — XGBoost calibré

7 Threshold Moving et analyse cost-sensitive

7.1 Optimisation du seuil

Avec des probabilités bien calibrées, on peut maintenant chercher le seuil qui minimise le coût total sur l'ensemble de validation. La figure suivante illustre comment ce coût évolue en fonction du seuil choisi : il n'est pas monotone, et le seuil de 0.5 est loin d'être optimal.




FIGURE 13 – Évolution du coût total en fonction du seuil de décision

7.2 Résultats après Threshold Moving

Modèle	Seuil optimal	Precision	Recall	Coût	FP	FN
Logistic Regression + Calibration	0.2029	0.7188	0.9200	30 063 000 €	9	2
Random Forest + Calibration	0.0404	0.7059	0.9600	15 070 000 €	10	1
XGBoost + Calibration	0.1358	0.8889	0.9600	15 021 000 €	3	1

TABLE 5 – Résultats après Threshold Moving

XGBoost calibré obtient le meilleur coût parmi les modèles Threshold Moving, avec seulement 3 faux positifs et 1 faux négatif. Mais ce faux négatif représente à lui seul 15 millions d'euros — ce qui explique pourquoi le coût total reste élevé même avec d'excellentes métriques statistiques. C'est là toute la tension du problème : on peut avoir un très bon modèle statistique et un coût économique encore considérable.




FIGURE 14 – Matrice de confusion avec seuil 0.5 (référence)




FIGURE 15 – Matrice de confusion avec seuil optimal




FIGURE 16 – Comparaison des coûts totaux par modèle





FIGURE 17 – Économies obtenues par rapport à une stratégie de référence

FIGURE 18 – Analyse de sensibilité selon c_{FN} et c_{FP}

L'analyse de sensibilité montre que le coût total est très sensible à c_{FN} . Plus ce coût augmente, plus le seuil optimal doit baisser, poussant le système vers une stratégie encore plus prudente.

8 Comparaison avec SMOTE

SMOTE est ajouté comme méthode de comparaison. Plutôt que de modifier la règle de décision après l'entraînement, il modifie les données d'entraînement elles-mêmes en créant des exemples synthétiques de la classe minoritaire.

Modèle	Méthode	Precision	Recall	Coût	FP	FN
Random Forest	SMOTE + seuil 0.5	0.7143	1.0000	70 000 €	10	0
XGBoost	Calibration + Threshold Moving	0.8889	0.9600	15 021 000 €	3	1
Random Forest	Calibration + Threshold Moving	0.7059	0.9600	15 070 000 €	10	1
Logistic Regression	Calibration + Threshold Moving	0.7188	0.9200	30 063 000 €	9	2

TABLE 6 – Comparaison finale des approches

Résultat-clé

SMOTE appliqué à la Random Forest domine empiriquement avec un coût total de seulement 70 000 € — soit 214 fois moins que XGBoost avec Threshold Moving. La raison est simple : SMOTE obtient un rappel parfait (0 faux négatif), et chaque faux négatif évité représente 15 millions d’euros.

Il faut cependant nuancer ce résultat. SMOTE répond à un problème statistique — le déséquilibre des classes — et sa performance sur ce test set, bien que spectaculaire, n’est pas garantie sur d’autres fenêtres temporelles. Le Threshold Moving, de son côté, est plus robuste théoriquement car il relie directement la règle de décision à la matrice de coûts. En pratique, combiner les deux approches — SMOTE à l’entraînement et Threshold Moving à la décision — constitue souvent la stratégie la plus solide.

9 Monitoring du Data Drift

9.1 Feature drift

Le module de drift compare les distributions des variables entre la période d’entraînement et des fenêtres récentes. Les résultats révèlent un drift critique sur plusieurs variables :

Variable	PSI	Sévérité
volume_moving_average_20	2.80	critique
price_moving_average_20	2.75	critique
Open / High / Low / Close	2.71–2.73	critique
Volume	1.05	critique
volume_moving_std_20	0.59	critique

TABLE 7 – Variables présentant un drift significatif ($\text{PSI} \geq 0.2$)

Ce résultat est attendu : en finance, les niveaux absolus de prix et de volume évoluent naturellement dans le temps. En revanche, les variables relatives — rendements, ratios de volatilité, volumes anormaux — restent beaucoup plus stables, ce qui justifie leur place centrale dans le feature engineering.

9.2 Label drift et dégradation du coût

Les fenêtres récentes présentent un taux de positifs d’environ 0.9%, contre 2.56% en période de référence — une baisse relative de 62 à 64%. Cela traduit une réduction de la fréquence des signaux suspects dans la période récente, et non une hausse du risque. Concernant la dégradation économique, les coûts restent stables sur toutes les configurations de modèles :

Modèle	Coût référence	Coût actuel	Drift coût
Logistic Regression calibrée	30 063 000 €	30 063 000 €	Non
Random Forest calibrée	15 070 000 €	15 070 000 €	Non
XGBoost calibré	15 021 000 €	15 021 000 €	Non

TABLE 8 – Monitoring de la dégradation du coût

Cette distinction est importante : tout drift statistique n'implique pas nécessairement une perte économique immédiate. Un système de surveillance mature doit suivre les deux dimensions.

9.3 Recalibration automatique

La détection d'un drift critique déclenche automatiquement une recalibration des seuils de décision :

Modèle	Ancien seuil	Nouveau seuil	FN après recalibration	TP
Logistic Regression	0.2029	0.1167	0	25
Random Forest	0.0404	0.0302	0	25
XGBoost	0.1358	0.0000	0	25

TABLE 9 – Seuils recalibrés après détection du drift

Les seuils sont abaissés pour augmenter la sensibilité et réduire le risque de faux négatif — réaction cohérente avec la logique cost-sensitive du projet. Le nouveau seuil de XGBoost, fixé à zéro, est extrêmement agressif et nécessiterait en production une contrainte sur le volume maximal d'alertes acceptables.

10 Dashboard interactif : Market Abuse Command Center

Un modèle seul ne constitue pas un système opérationnel. Pour qu'il soit utile à un analyste de conformité, il doit être présenté dans une interface permettant de comprendre les alertes, comparer les stratégies et simuler les coûts en temps réel. C'est l'objectif du *Market Abuse Command Center*, développé avec Dash et Plotly, organisé autour de sept espaces fonctionnels.

Le **Risk Command Center** offre une vue synthétique : nombre d'observations, fréquence des événements suspects, actif le plus risqué, meilleure stratégie et coût minimal. Il sert de point d'entrée décisionnel pour un responsable de conformité.

La **Live Market Timeline** transforme les observations suspectes en événements temporels navigables, permettant de visualiser quand les signaux apparaissent et avec quelle intensité.

Le **Model Arena** compare les modèles non pas par leur accuracy, mais par leur coût économique total — inversant ainsi la logique d'évaluation conventionnelle.

Le **Cost Simulator** permet d'explorer interactivement comment le seuil de Bayes évolue quand on modifie c_{FN} ou c_{FP} , rendant la logique cost-sensitive accessible et pédagogique.

L'**Alert Investigation Room** est orientée vers l'analyste opérationnel : elle permet d'explorer chaque observation suspecte, de comprendre quels signaux ont déclenché l'alerte et d'évaluer sa priorité.

Le **Drift Monitoring Center** centralise la surveillance dynamique : variables en drift, évolution du taux de positifs, comparaison des coûts avant et après drift, et seuils recalibrés.

Conclusion

Ce projet a démontré qu'il est possible de construire un système de surveillance financière qui dépasse les limites des approches classiques de classification. En partant de données réelles de marché et en construisant des variables financières pertinentes, nous avons développé une chaîne complète qui va de la prédiction probabiliste à la décision économique justifiée.

La baseline montre que les modèles peuvent détecter les signaux suspects avec de très bonnes métriques statistiques. Mais c'est le passage à une logique cost-sensitive qui constitue la vraie valeur ajoutée : Threshold Moving adapte le seuil à l'asymétrie des coûts, SMOTE améliore la détection de la classe rare, et leur combinaison offre la stratégie la plus robuste. Le résultat empiriquement dominant — Random Forest avec SMOTE à 70 000 € de coût total contre 15 millions pour XGBoost seul — illustre concrètement ce que signifie décider en fonction du coût plutôt qu'en fonction de l'accuracy.

Le module de drift monitoring ajoute une dimension opérationnelle indispensable. Il rappelle qu'un modèle de machine learning n'est pas un artefact figé : il doit être surveillé, évalué dans le temps, et recalibré lorsque le marché change. Enfin, le *Market Abuse Command Center* transforme l'ensemble du pipeline en outil de décision accessible, explicable et aligné avec les réalités métier.

Contribution principale

Ce projet démontre que la vraie valeur d'un modèle ne réside pas dans sa performance statistique, mais dans sa capacité à devenir un outil de décision robuste, surveillé, explicable et aligné avec les coûts économiques réels de l'erreur.